

Prova de conceito: clusterização de municípios

Que tipos de praça existem no Brasil para vender fiança — dados, estatística, baseline e resultados

- A escolha das variáveis
- Os dados e a estatística descritiva
- Os conjuntos e os testes que rodamos
- Os baselines, os resultados e a conclusão

Em uma frase, o que é esta POC

Agrupar municípios por tipo de mercado de fiança, sem rótulo para aprender

- Unidade de análise: os 687 municípios com 50 mil habitantes ou mais.
- É não supervisionado: não existe 'praça boa' rotulada para o modelo aprender.
- Por isso a prova não é acurácia. A prova é: separa melhor do que o que já temos de graça, que é geografia e tamanho de cidade?
- Tudo por habitante, para o agrupamento não virar só um ranking de cidade grande.

Como escolhemos as variáveis

Não partimos de 'que dado existe?'. Partimos das perguntas que alguém precisa responder para decidir se vale vender fiança numa cidade. Cada pergunta virou uma dimensão, e cada dimensão puxou variáveis.

A pergunta de negócio	As variáveis que respondem
Existe mercado?	administradoras e imobiliárias por 10 mil hab., imobiliárias abertas em 12 meses
O inquilino paga?	Pix de pessoa física por hab., salário mediano de admissão, poupança per capita, automóveis por hab.
Qual o risco?	famílias no CadÚnico, alavancagem (crédito sobre poupança), crédito per capita
Tem demanda entrando?	crescimento da população, admissões de 18 a 30 anos, saldo de emprego
Dá para anunciar?	internet móvel 4G/5G de pessoa física, banda larga fixa
Tem concorrente?	corretores de seguros por 10 mil hab. (quem vende seguro-fiança)

Cada variável é relativa à população, e cada uma precisou passar pela regra de data: nada anterior a 2025.

De onde veio cada dado, e de quando

Órgão produtor	Quantas variáveis	Referência mais recente
Banco Central	4	2026-08
Receita Federal	4	2026-01-11
Novo CAGED	3	2026-01
Anatel	2	2026-07
IBGE	1	2026-07-01
Ministério do Desenvolvimento e Assistência Social	1	2026-09
Senatran	1	2026-07

- **16 variáveis candidatas, todas de fonte pública e oficial.**
- **Regra do projeto: nada anterior a 2025. Conferida por código — a execução aborta se alguma fonte regredir.**
- Uma fonte foi descartada por isso: o índice de conectividade da Anatel, que para em 2024.

Os dados batem com a realidade?

Antes de qualquer modelo, somamos cada base e comparamos com a ordem de grandeza conhecida do país. É o teste que pega erro silencioso de extração.

Base	Total no Brasil	Quanto está no nosso universo
ESTBAN, operações de crédito	R\$ 6.6 trilhões	93%
Senatran, automóveis	65.6 milhões	78%
Anatel, acessos móveis 4G e 5G	246.2 milhões	79%
CNPJ, imobiliárias e administradoras ativas	144.872 estabelecimentos	91%
Novo CAGED, admissões em 12 meses	26.3 milhões	83%
CadÚnico, famílias cadastradas	43.4 milhões	62%

Zero valores faltantes nas 16 variáveis, nos 687 municípios

Estatística descritiva: o que a distribuição obrigou


- 7 das 16 variáveis têm cauda longa à direita (assimetria > 1). Nelas aplicamos log.
- Antes do log, winsorizamos 1% nas duas caudas. Motivo concreto: o Banco Central registra o crédito onde o banco está sediado.

Variável	Assimetria antes	Assimetria depois do corte
Crédito per capita (R\$)	20,24	2,04
Poupança e depósito a prazo per capita (R\$)	15,11	2,77
Imobiliárias e corretoras / 10 mil hab.	11,29	2,33
Crédito sobre poupança (alavancagem)	9,06	2,18

Osasco aparecia com R\$ 1 milhão de crédito por habitante: é a carteira nacional de um banco, não o crédito dos moradores. Sem tratar, essa única cidade dominaria o modelo.

A distribuição de cada variável

Distribuição das variáveis nos 687 municípios



Correlação e VIF: o que saiu do modelo

- Regra: par com correlação de Spearman acima de 0,80 em módulo, fica só uma variável.
- O desempate não é automático: fica a que carrega sentido de negócio. Administradoras de imóveis (CNAE 6822) é proxy de LOCAÇÃO, que é o mercado da fiança; imobiliárias (6821) inclui venda.

Saiu	Ficou no lugar	Correlação
Imobiliárias e corretoras / 10 mil hab.	Administradoras de imóveis / 10 mil hab.	0,824
Veículos por habitante	Famílias no CadÚnico / 100 domicílios	0,81
Corretores de seguros / 10 mil hab.	Poupança e depósito a prazo per capita (R\$)	0,802

Depois do corte, o maior VIF é 6.56 — bem abaixo do limiar usual de 10. Não há multicolinearidade grave.

Os 5 conjuntos de variáveis que montamos

Em vez de escolher um conjunto e defender, montamos cinco e deixamos competir. Cada um testa uma hipótese diferente sobre o que define uma praça.

Conjunto	A hipótese que ele testa	Variáveis
A	Mercado imobiliário	4
B	Capacidade de pagamento	5
C	Mercado + renda	6
D	Mercado + renda + marketing	6
E	Mercado + risco + concorrência + demanda	7

- **O conjunto E nasceu depois, de um resultado negativo: montamos um grupo só com risco, concorrência e demanda para ver se separava melhor. Não separou.**

Os testes que rodamos

```
# o mesmo pipeline para todos os conjuntos, sem exceção  
winsorizar 1% -> log nas assimétricas -> padronizar -> modelo  
  
# e então, para cada conjunto:  
5 conjuntos x 3 algoritmos x k de 2 a 10 = 135 combinações
```

KMeans, Aglomerativo (Ward) e Mistura Gaussiana. Semente fixa em 42.


- **4 métricas em cada combinação: inércia (cotovelo), silhueta, Davies-Bouldin e Calinski-Harabasz.**
- **3 baselines para comparar: as 5 regiões do IBGE, faixas de porte populacional e sorteio aleatório.**
- **2 testes de robustez: estabilidade sob reamostragem e ablação, removendo uma variável por vez.**

4 • TESTES

A escolha de k, e um achado que incomoda

- A silhueta é máxima em $k = 2$ em quase todas as combinações, e cai a partir daí.
- Isso não é bug: quer dizer que o Brasil municipal, nessas variáveis, é um CONTÍNUO. Não existem grupos cravados esperando para serem achados.
- Aceitar $k = 2$ entregaria 'cidade rica e cidade pobre', que não orienta decisão nenhuma.
- Por isso k saiu do COTOVELO da inércia, e a qualidade foi julgada pelo baseline.


Escolha de k por grupo de variáveis, modelo KMeans



O BASELINE: é aqui que a POC passa ou não passa

Um agrupamento só se justifica se for melhor do que o que já se tem sem modelo nenhum. Comparamos os três no MESMO espaço de variáveis, então a silhueta é comparável.

Silhueta (maior é melhor)




Passou: o cluster ganha da geografia, do porte e do sorteio

- E o mais importante: Rand ajustado contra porte = 0.032. O modelo NÃO redescobriu o tamanho da cidade, que era o risco principal.
- Contra região = 0.185: tem alguma relação com geografia, esperado num país desigual, mas longe de ser a mesma coisa.

Robustez: o resultado sobrevive a mexer nos dados?


- Reamostragem: tiramos 20% dos municípios, rodamos de novo, 99 vezes. Concordância média (Rand ajustado) de 0.847.
- 10 sementes aleatórias diferentes: praticamente a mesma solução.
- Ablação: tirando cada variável, nenhuma sozinha derruba a separação.



E serve como variável para um modelo futuro?

Última prova, e a que mais importa para o projeto seguir: o rótulo do cluster acrescenta informação que região e porte já não dão? R^2 ajustado, em variáveis municipais deixadas fora do modelo.

Ganho no R^2 ajustado ao somar o cluster a região + porte



Acrescenta em 15 de 15 variáveis testadas, ganho médio +0.0435. Em nenhuma piora.


Resultado: 5 tipos de praça

Tipo de praça	Municípios	% da população
Praça em formação	73	4,9
Praça intermediária conectada	219	19,2
Praça popular de grande porte	167	23,7
Praça sem mercado formal	97	4,8
Praça madura de locação	131	47,5


Para reconhecer	Exemplos
Praça madura de locação	São Paulo, Rio, Brasília, Fortaleza
Praça popular de grande porte	Manaus, Belém, Maceió, São Gonçalo
Praça intermediária conectada	Caxias do Sul, Mogi das Cruzes, Betim
Praça em formação	Belford Roxo, Caucaia, Águas Lindas
Praça sem mercado formal	interior do Maranhão e da Paraíba

O mapa

Tipos de praça para o produto de fiança
municípios com 50 mil habitantes ou mais



O perfil de cada praça



E o que isso muda na decisão de mídia

Praça em formação

Momento de entrada. Mídia de educação de produto para imobiliária nova, custo por lead ainda baixo.

Praça intermediária conectada

Praça de teste A/B de criativo. Verba pequena e recorrente em Meta e TikTok para aprender antes de levar o aprendizado às praças maduras.

Praça popular de grande porte

Praça de volume, mas de captação antes de conversão. Mídia para recrutar imobiliária nova, com meta de custo por imobiliária cadastrada, não por lead de inquilino. Verba média e análise de risco mais rígida na esteira.

Praça sem mercado formal

Zero verba de mídia paga. Praça de exclusão no planejamento.

Praça madura de locação

Mídia de conversão para imobiliária (Meta e Google Search em segmentação B2B), com verba concentrada e meta de custo por lead.

Conclusão

A prova de conceito passou, com uma ressalva honesta

- **Passou:** silhueta 0.236 contra -0.001 da geografia e -0.098 do porte. É estável e acrescenta informação em 15 de 15 variáveis retidas.
- **A ressalva:** os grupos não são naturais. São um corte útil de um contínuo, e a defesa deles é a comparação com o baseline, não a separação absoluta.
- **O que ainda não conseguimos:** dizer quanto a Loft ganha em cada praça. Isso exige dado interno de receita e sinistro, que não temos.
- **Próximo passo natural:** cruzar os clusters com esse dado interno e transformar 'praça promissora' em retorno esperado por real investido.