

Onde colocar o próximo R\$ 1 em média paga?

POC não supervisionada: os tipos de praça que existem no Brasil para vender o produto de fiança da Loft

- 687 municípios com 50 mil habitantes ou mais
- 16 variáveis de 8 fontes públicas, nenhuma anterior a 2025
- 5 tipos de praça que superam geografia e porte populacional
- O cluster acrescenta informação em 15 de 15 testes de validação

O que você vai ver

- 1. O problema — por que a resposta depende da praça, e não só do canal
- 2. Os dados — 8 fontes públicas, e as decisões de tratamento que mudaram o resultado
- 3. O método — log, padronização, 5 grupos de variáveis, 3 algoritmos, k de 2 a 10
- 4. Os resultados — inclusive um achado desconfortável e um erro que corrigimos
- 5. Os 5 tipos de praça — perfil, mapa e o que cada um significa para a fiança
- 6. Limitações e próximos passos

Duas coisas para guardar desde já: a análise agrupa MERCADOS, não clientes, porque não temos dado interno da Loft. E toda afirmação numérica desta apresentação é lida das tabelas da execução, não digitada à mão.

1

O problema

Onde colocar o próximo real, e por que isso é uma pergunta sobre praça

PROBLEMA

A pergunta do projeto

Onde colocar o próximo R\$ 1 em mídia paga?

- A Loft é 100% B2B: 7 produtos para 4 públicos diferentes.
- **A auditoria pública dos anúncios mostrou que ~74% das peças são de FIANÇA.**
- **E o cliente principal da fiança é a IMOBILIÁRIA, não o inquilino.**
- Minha tese: a resposta depende de PRODUTO × PÚBLICO × PRAÇA.
- Produto e público a auditoria já respondeu. Falta a praça — é o que esta POC ataca.

A pergunta que esta análise responde: quais tipos de praça existem no Brasil para vender fiança, e o que isso muda na decisão de mídia?

PROBLEMA

Por que não supervisionado, e o que então valida o resultado

- Não existe rótulo de 'praça boa' para aprender. Não há y.
- Sem dado interno da Loft, o objeto de agrupamento é MERCADO, não cliente.
- Logo a validação não pode ser acurácia. São três provas:
- (a) Separação interna — silhueta, Davies-Bouldin e Calinski-Harabasz
- (b) Superioridade sobre o que a Loft já teria de graça — geografia e tamanho de cidade
- (c) Estabilidade — o agrupamento sobrevive a reamostrar os municípios?

E uma quarta prova, que é a que responde 'isso serve para modelo?': valor incremental

2

Os dados

8 fontes públicas, 687 municípios, e as decisões que mudaram o resultado

Unidade de análise

- **Município brasileiro com 50 mil habitantes ou mais: 687 municípios.**
- Estimativa do IBGE de 2026, a mais recente publicada.
- Concentram 69,8% da população do país.
- **Todas as variáveis são relativas à população: por habitante, por 10 mil habitantes ou por 100 domicílios.**
- Isso é deliberado: sem relativizar, o agrupamento separaria só por tamanho de cidade, que é informação que a Loft já tem de graça.

Faixa de porte populacional	Municípios
1 milhão ou mais	15
100 a 250 mil	212
250 a 500 mil	77
50 a 100 mil	349
500 mil a 1 milhão	34

DADOS

As fontes, e a data de referência de cada uma

Variável	Órgão produtor	Referência
Administradoras de imóveis / 10 mil hab.	Receita Federal	2026-01-11
Crédito sobre poupança (alavancagem)	Banco Central	2025-09
Banda larga fixa / 100 hab.	Anatel	2025-09
Famílias no CadÚnico / 100 domicílios	Ministério do Desenvolvimento e Assistência Social	2026-09
Corretores de seguros / 10 mil hab.	Receita Federal	2026-01-11
Crédito per capita (R\$)	Banco Central	2025-09
Crescimento da população em 1 ano (%)	IBGE	2026-07-01
Imobiliárias e corretoras / 10 mil hab.	Receita Federal	2026-01-11
Imobiliárias novas em 12 meses (%)	Receita Federal	2026-01-11
Internet móvel 4G/5G de pessoa física / 100 hab.	Anatel	2026-07
Admissões de 18 a 30 anos (%)	Novo CAGED	2026-01
Pix de pessoa física por habitante	Banco Central	2026-08
Poupança e depósito a prazo per capita (R\$)	Banco Central	2025-09
Salário mediano de admissão (R\$)	Novo CAGED	2026-01
Saldo de emprego / admissões em 12 meses (%)	Novo CAGED	2026-01
Veículos por habitante	Senatran	2026-07

As descritoras (PNAD Contínua, SCR do Banco Central, FipeZap e Google Trends) não entram no cluster: só ajudam a nomear os grupos depois.

A regra de datas não é afirmada: é conferida em código

- **Regra do projeto: proibido usar Censo 2022 ou qualquer dado de 2024 ou anterior.**
- Conferido nas 16 variáveis do modelo. Nenhuma violação.
- A execução ABORTA se numa coleta futura alguma fonte regredir.

```
violacoes = diagnostico.violacoes_da_regra_de_datas(fontes)
if not violacoes.empty:
    raise RuntimeError(
        "Regra de datas violada: estas variáveis do modelo têm referência anterior a "
        f"{diagnostico.ANO_MINIMO_PERMITIDO}:\n{violacoes.to_string(index=False)}"
    )
```

pipeline.py — o pipeline se recusa a rodar com dado velho

Uma fonte foi DESCARTADA por causa disso: o Índice Brasileiro de Conectividade da Anatel, cujo ano mais recente é 2024. No lugar dele entraram os acessos de telefonia móvel dos dados abertos da Anatel, com referência de 2026-07.

DADOS

Os números batem com a realidade?

Este é o teste que pega erro de extração silencioso: unidade trocada, ou junção que multiplica registros. Se a parcela no universo passasse de 100%, haveria duplicação.

Base	Total no Brasil	Nos municípios analisados	Parcela
ESTBAN, operações de crédito	R\$ 6.6 trilhões	R\$ 6.1 trilhões	93%
Senatran, automóveis	65.6 milhões	51.1 milhões	78%
Anatel, acessos móveis 4G e 5G	246.2 milhões	193.4 milhões	79%
CNPJ, imobiliárias e administradoras ativas	144.872 estabelecimentos	131.316 estabelecimentos	91%
Novo CAGED, admissões em 12 meses	26.3 milhões	21.8 milhões	83%
CadÚnico, famílias cadastradas	43.4 milhões	26.9 milhões	62%

Zero valores faltantes nas 16 variáveis, nos 687 municípios

DADOS

Achado de brinde nessa conferência

- O crédito e as imobiliárias estão ~92% concentrados nos municípios grandes.
- Mas o CadÚnico só tem 62% nesses mesmos municípios.
- Tradução: a vulnerabilidade social está desproporcionalmente FORA das cidades grandes.
- Isso importa para a fiança: o risco não está onde está o mercado.

Parcela do total nacional que está nos municípios analisados



DADOS

7 decisões de tratamento que mudaram o resultado

Decisão	Evidência que obrigou a decisão
Pix: descartar mês em andamento	set/26 vinha com 71% do volume típico
Salário: mediana, não média	num município a média era R\$3.634 e a mediana R\$1.612
Internet móvel: só pessoa física	com PJ, um município marcava 881 acessos/100 hab
Veículos: automóveis, não a frota	moto cresce onde a renda cai: sinal oposto
Crédito: winsorizar 1% nas caudas	o ESTBAN registra a carteira na sede do banco
Google Trends: virou descritora	a API devolve UF, não município
CadÚnico: denominador estimado	a competência não traz contagem de pessoas

Cada um desses números é recalculado a cada execução. Nenhum está colado no texto.

DADOS

Código 1: como o mês incompleto é descartado sozinho

Setembro de 2026 aparecia na API do Banco Central com R\$784 bi contra ~R\$1.100 bi dos meses fechados, porque o mês ainda estava em andamento. Usar esse mês rebaixaria artificialmente todos os municípios.

```
FRACAO_MINIMA_MES_COMPLETO = 0.85

def meses_completos(df):
    """Descarta meses cujo volume nacional indica mês ainda em andamento."""
    total = df.groupby("AnoMes")["VL_PagadorPF"].sum().sort_index()
    mediana = total.median()
    return sorted(total[total >= mediana * FRACAO_MINIMA_MES_COMPLETO].index.tolist())
```

coleta/pix.py — a regra é relativa à mediana, então funciona em qualquer mês

Tem teste automatizado: mês com 30% do volume típico é reprovado

DADOS

Código 2: baixar 2,4 MB de um arquivo de 3,2 GB

Os acessos de telefonia móvel da Anatel só existem num ZIP de 3,2 GB. Combinamos não baixar nada acima de 1 GB. A saída foi ler o índice do ZIP por requisição de faixa e extrair só o membro necessário.

```
class _ArquivoRemoto(io.RawIOBase):
    """Arquivo somente-leitura servido por HTTP Range."""
    def readinto(self, buffer):
        dados = self.read(len(buffer))
        buffer[: len(dados)] = dados
        return len(dados)

with zipfile.ZipFile(io.BufferedReader(_ArquivoRemoto(ZIP_MOVEL))) as z:
    with z.open(_membro_mais_recente(z)) as f:
        bruto = pd.read_csv(f, sep=";", encoding="utf-8-sig")
```

coleta/anatel.py — 2,4 MB baixados em vez de 3,19 GB

3

O método

Pipeline, corte de variáveis, e 5 grupos testados contra 3 algoritmos

O pipeline

- **Winsorizar 1% nas duas caudas → log nas variáveis de cauda longa → padronizar → modelo**
- A winsorização existe porque fontes bancárias registram a operação na sede da empresa.
- O log entra só onde a assimetria passa de 1 e a variável é não negativa.
- Semente fixa em 42 em tudo.

```
def construir_preparo(variaveis, variaveis_log):  
    """log nas variáveis de cauda longa, depois padronização em todas."""  
    blocos = [  
        ("log", Pipeline([("log", FunctionTransformer(np.log1p)),  
                          ("escala", StandardScaler())]), variaveis_log),  
        ("direto", StandardScaler(), diretas),  
    ]  
    return ColumnTransformer(blocos)
```

clustering.py — o preparo é feito dentro de cada reamostragem, para não vazar

MÉTODO


Corte de variáveis: correlação acima de 0,80 fica só uma

Variável descartada	Variável mantida	Correlação
Imobiliárias e corretoras / 10 mil hab.	Administradoras de imóveis / 10 mil hab.	0,824
Veículos por habitante	Famílias no CadÚnico / 100 domicílios	0,81
Corretores de seguros / 10 mil hab.	Poupança e depósito a prazo per capita (R\$)	0,802

- **O desempate NÃO é automático: fica a variável que o desenho usa em mais grupos, porque é a que carrega sentido de negócio.**
- Administradoras de imóveis (CNAE 6822) é proxy de LOCAÇÃO, que é o mercado da fiança. Imobiliárias (6821) inclui venda. Por isso administradoras fica.
- Maior VIF depois do corte: 6.56 — bem abaixo do limiar de 10.

MÉTODO

A correlação entre as variáveis



reports/figures/03_correlacao.png

MÉTODO

Os 5 grupos de variáveis comparados

Grupo	O que ele testa	Vars	Exemplos de variável
A	Mercado imobiliário	4	Administradoras de imóveis, Imobiliárias e corretoras , Imobiliárias novas em
B	Capacidade de pagamento	5	Pix de pessoa física por h, Salário mediano de admissã, Famílias no CadÚnico /
C	Mercado + renda	6	Administradoras de imóveis, Imobiliárias novas em 12 m, Pix de pessoa física p
D	Mercado + renda + marketing	6	Administradoras de imóveis, Imobiliárias novas em 12 m, Pix de pessoa física p
E	Mercado + risco + concorrência + demanda	7	Administradoras de imóveis, Imobiliárias novas em 12 m, Crédito sobre poupança

- **A hipótese inicial era que o grupo D (com marketing) separaria melhor.**
- **O grupo E nasceu DEPOIS, de um resultado negativo — conto isso no fim.**
- Total de combinações testadas: 5 grupos × 3 algoritmos × k de 2 a 10 = 135.

4


Os resultados

Um achado desconfortável, o teste de aceite, e um erro que corrigimos

RESULTADOS

Achado desconfortável: $k = 2$ quase sempre ganha

Escolha de k por grupo de variáveis, modelo KMeans



- A silhueta é máxima em $k=2$ e cai de forma monotônica. Isso não é bug.
- Significa que o Brasil municipal, nessas variáveis, é um CONTÍNUO — não tem grupos cravados.
- Aceitar $k=2$ entregaria 'praça rica e praça pobre', que não orienta decisão de mídia.

RESULTADOS

Então como escolhemos k, o grupo e o algoritmo

- 1. k sai do COTOVELO da inércia, não do máximo da silhueta.
- 2. Só concorrem grupos que respondem à pergunta: precisam ter ao menos uma variável de mercado E uma de capacidade de pagamento. Isso elimina A e B.
- 3. Todos os clusters precisam ter no mínimo 20 municípios, senão não é praça, é exceção.
- 4. Quando a silhueta empata dentro de 0,02, o desempate é ESTABILIDADE.


Grupo	Algoritmo	k	Silhueta	Menor cluster
Capacidade de pagamento	KMeans	4	0,325	79
Capacidade de pagamento	Aglomerativo (Ward)	4	0,319	49
Mercado imobiliário	KMeans	4	0,305	86
Capacidade de pagamento	Mistura Gaussiana	4	0,256	49
Mercado imobiliário	Aglomerativo (Ward)	4	0,253	40
Mercado + renda	KMeans	5	0,244	97
Mercado + renda + marketing	KMeans	5	0,236	73

B e A lideram a silhueta pura — mas a silhueta premia espaços com menos variáveis e mais redundantes, e nenhum dos dois responde à pergunta sozinho.

RESULTADOS

O TESTE DE ACEITE: o cluster ganha de geografia e de porte?

Silhueta no MESMO espaço de variáveis (maior é melhor)




Silhueta 0.236 contra -0.001 da geografia e -0.098 do porte

- **Rand ajustado contra PORTE: 0.032** — o modelo **NÃO** redescobriu o tamanho da cidade. Esse era o risco principal.
- Rand ajustado contra REGIÃO: 0.185 — existe alguma relação com geografia, o que é esperado num país desigual, mas longe de ser a mesma coisa.

RESULTADOS

Robustez: o agrupamento sobrevive a mexer nos dados?

- Reamostragem (99 comparações, subamostras de 80% dos municípios): Rand ajustado médio 0.847.
- 10 sementes diferentes: Rand médio 0.991 contra a solução de referência.
- Sem reposição de propósito: com reposição, municípios duplicados ficam a distância zero e inflam a concordância.
- E o preparo (winsorizar, log, padronizar) é REFEITO dentro de cada subamostra — senão a estabilidade sai otimista.



Ablação: quanto cada variável sustenta a separação

RESULTADOS

C contra D: a escolha foi um julgamento, e está registrado

Grupo finalista	k	Silhueta	Estabilidade
Mercado + renda + marketing	5	0,236	0,838
Mercado + renda	5	0,244	0,702

- C separa um pouco melhor, e isso foi TESTADO: reamostrando 200 vezes, o intervalo de 95% da diferença é [-0.0323; -0.0010] — a vantagem de C é real.
- Mas é pequena. E os clusters de C NÃO se reproduzem: 0,70 de estabilidade contra 0,84 de D.
- Troquei 0,008 de separação por 0,137 de reprodutibilidade, porque a decisão de mídia vai ser refeita mês a mês e agrupamento que se reorganiza não sustenta plano de verba.


RESULTADOS

O teste que responde: isso serve para um modelo futuro?

Separação e estabilidade dizem que o agrupamento é consistente. Não dizem se ele é ÚTIL. A pergunta certa não é se o cluster substitui a geografia — é se ele ACRESCENTA a ela.

Teste: R^2 AJUSTADO de (região + porte) contra (região + porte + cluster), em variáveis municipais que ficaram fora do modelo. Ajustado para não premiar só o aumento de parâmetros.

Ganho no R^2 ajustado ao adicionar o cluster (7 maiores de 15)



O cluster acrescenta em 15 de 15 variáveis retidas. Ganho médio +0.0435. Em nenhuma ele piora.

RESULTADOS

O erro que eu cometi, e por que ele importa

- **O primeiro teste que fiz foi outro: pedir que o cluster VENCESSE a região.**
- Nesse formato ele perdeu: 2 de 7 variáveis, ganho médio -0,011. Quase concluí que a análise não servia.
- **O teste estava mal formulado.**
- No Brasil quase toda variável socioeconômica municipal é muito explicada pela região. Exigir que o agrupamento derrote a geografia é exigir que ele seja um proxy melhor de desigualdade regional — que não é a função dele.
- **A função é separar praças que devem receber o mesmo tratamento de mídia. Para isso o que importa é informação incremental.**

A pergunta feita	Resultado	Ganho médio de R ²
Cluster SUBSTITUI região + porte	perde: 2 de 7	-0,011
Cluster SOMA a região + porte	ganha: 15 de 15	+0.0435

RESULTADOS

O grupo E: um experimento que falhou, e fica registrado

Depois do resultado negativo, montei um grupo só com variáveis específicas de fiança — nada de nível socioeconômico geral:

- Alavancagem (crédito sobre poupança) — RISCO de inadimplência por município. O SCR do Banco Central só tem isso por UF; essa é municipal.
- Reserva per capita (poupança + depósito a prazo) — o colchão que sustenta o aluguel.
- Corretores de seguros / 10 mil hab. — oferta local do seguro-fiança, o CONCORRENTE direto.
- Crescimento da população em 1 ano — motor da DEMANDA de locação.
- Admissões de 18 a 30 anos — a faixa que aluga.

O grupo E PERDEU: silhueta 0.184 contra 0.236 do grupo D

Fica no relatório porque experimento que falha também é resultado: mostra que risco e demanda são conceitualmente certos, mas mais ruidosos que mercado e renda.

RESULTADOS

E o cluster 'em formação' não é artefato: foi testado

A taxa de imobiliárias novas é uma proporção sobre base pequena: num município com 9 imobiliárias, três aberturas já viram 33%. Precisava testar se o cluster era só isso.

Exige no mínimo	Municípios	Mediana no cluster	Mediana no resto	p-valor
1	73	27,3	12,5	1e-37
10	36	24,3	12,9	5,1e-19
20	15	21,1	13,1	1,1e-08
50	2	23,6	13,3	0,011

Exigindo 20+ imobiliárias, o cluster mantém 21,1% de novas contra 13,1% do resto (p = 1,1e-08)


5

Os 5 tipos de praça

O que existe no Brasil para vender fiança, e o que fazer em cada um


RESULTADOS

O perfil dos 5 clusters



RESULTADOS


A assinatura de cada praça



RESULTADOS

Onde eles estão no mapa

Tipos de praça para o produto de fiança
municípios com 50 mil habitantes ou mais



RESULTADOS

Quanto cada tipo de praça representa

Tipo de praça	Municípios	% dos municípios	% da população	População mediana
Praça em formação	73	10,6	4,9	80.435
Praça intermediária conectada	219	31,9	19,2	98.241
Praça popular de grande porte	167	24,3	23,7	119.224
Praça sem mercado formal	97	14,1	4,8	64.350
Praça madura de locação	131	19,1	47,5	221.023

- A praça madura é 19% dos municípios e quase metade da população.
- As duas praças de exclusão (sem mercado formal e em formação) juntas são ~10% da população.

RESULTADOS

Os maiores municípios de cada praça

Tipo de praça	Os 4 maiores municípios
Praça em formação	Belford Roxo/RJ, Caucaia/CE, Águas Lindas de Goiás/GO, Nossa Senhora do Socorro/SE
Praça intermediária conectada	Aparecida de Goiânia/GO, Caxias do Sul/RS, Mogi das Cruzes/SP, Betim/MG
Praça popular de grande porte	Manaus/AM, Belém/PA, Maceió/AL, São Gonçalo/RJ
Praça sem mercado formal	São José de Ribamar/MA, Timon/MA, Caxias/MA, Santa Rita/PB
Praça madura de locação	São Paulo/SP, Rio de Janeiro/RJ, Brasília/DF, Fortaleza/CE

Reconhecimento imediato: a praça madura é São Paulo, Rio, Brasília e Fortaleza. A praça popular de grande porte é Manaus, Belém, Maceió. A sem mercado formal é o interior do Maranhão e da Paraíba.

RESULTADOS

Validação externa: as descritoras confirmam sozinhas

Estas variáveis NÃO entraram no modelo. Se elas ordenam os clusters de forma coerente, é sinal de que os grupos capturaram algo real, e não ruído.

Tipo de praça	% alugados (UF)	Inadimpl. PF (UF)	Busca fiança	Imobiliárias/10k
Praça em formação	20,26	4,98	14,75	0,83
Praça intermediária conectada	25,37	3,88	45,14	4,12
Praça popular de grande porte	22,2	4,86	22,63	2,02
Praça sem mercado formal	19,17	5,2	11,87	0,51
Praça madura de locação	26,39	3,97	42,35	11,73

- A praça SEM MERCADO FORMAL tem a MAIOR inadimplência e a MENOR busca por fiança.
- A praça MADURA tem o maior % de domicílios alugados e 11,7 imobiliárias por 10 mil hab.

O que cada praça significa para a fiança

Praça em formação (73 municípios, 4.9% da população)

Muita imobiliária abrindo agora: o mercado está se organizando e as empresas novas ainda não têm processo de garantia definido.

Praça intermediária conectada (219 municípios, 19.2% da população)

Mercado e renda medianos, mas alcance digital alto: dá para testar barato com boa cobertura de audiência.

Praça popular de grande porte (167 municípios, 23.7% da população)

Cidade grande com muita gente e muito contrato potencial, mas o mercado formal de locação é raso para o tamanho dela e a vulnerabilidade está acima da média. A fiança cabe, só que o gargalo não é demanda: é falta de imobiliária organizada para vender.

Praça sem mercado formal (97 municípios, 4.8% da população)

Praticamente não existe administradora formal e a vulnerabilidade é alta: não há cliente B2B para vender e o risco de inadimplência é o maior.

Praça madura de locação (131 municípios, 47.5% da população)

Muitas administradoras e inquilino com capacidade de pagar: o risco da fiança é baixo e o cliente B2B já existe e já vende locação.

A ação de mídia recomendada em cada praça

Praça em formação

Momento de entrada. Mídia de educação de produto para imobiliária nova, custo por lead ainda baixo.

Praça intermediária conectada

Praça de teste A/B de criativo. Verba pequena e recorrente em Meta e TikTok para aprender antes de levar o aprendizado às praças maduras.

Praça popular de grande porte

Praça de volume, mas de captação antes de conversão. Mídia para recrutar imobiliária nova, com meta de custo por imobiliária cadastrada, não por lead de inquilino. Verba média e análise de risco mais rígida na esteira.

Praça sem mercado formal


Zero verba de mídia paga. Praça de exclusão no planejamento.

Praça madura de locação

Mídia de conversão para imobiliária (Meta e Google Search em segmentação B2B), com verba concentrada e meta de custo por lead.

VALOR

O mapa de decisão



Densidade de administradoras × capacidade de pagamento; tamanho do círculo é a população

6

Limitações e próximos passos

O que esta POC não responde, e o que faria ela virar decisão

Limitações — as que mais importam

- 1. Sem dado interno da Loft. Descrevemos o MERCADO, não o desempenho da Loft nele. Só o dado interno transforma 'praça promissora' em 'praça rentável'.
- 2. Os grupos não são naturais. São um corte útil de um contínuo. A defesa deles é a comparação com os baselines e o valor incremental, não a separação absoluta.
- 3. CNAE não é produto. 6821 e 6822 não distinguem locação de venda nem residencial de temporada. Por isso praças de veraneio aparecem com densidade altíssima de imobiliária sem serem mercado de fiança.
- 4. Efeito de sede. ESTBAN e telefonia móvel registram a operação onde a empresa está sediada. Tratamos com winsorização e filtro de pessoa física, mas o viés não desaparece.
- 5. A escolha entre C e D é um julgamento, não um resultado automático — e está registrado.

Próximos passos, em ordem de valor

- 1. Cruzar com o dado interno da Loft: receita e sinistro de fiança por município. Transforma os clusters em faixas de retorno esperado por real investido.
- 2. Separar locação de venda usando CNAE secundária e razão social, para isolar a praça de temporada da praça de locação residencial.
- 3. Testar de verdade: dois municípios por cluster, mesma campanha, medir custo por lead qualificado. É o que valida se o cluster prediz desempenho de mídia.
- 4. Intenção de busca por município via Google Ads Keyword Planner, que tem granularidade melhor que o Trends.
- 5. Rodar mensalmente e acompanhar a migração de municípios entre clusters como sinal antecedente de mercado em formação.

Como reproduzir tudo isso

```
# cria o ambiente, coleta as fontes, gera tabelas, figuras e relatório
make poc

# refaz o download de todas as fontes oficiais
make poc-completa

# os testes da lógica que, se quebrar, contamina o resultado sem dar erro
PYTHONPATH=src .venv/bin/python -m pytest tests/
```

Um comando. Semente fixa. Dependências fixadas com == no requirements.txt.

Números da entrega	Valor
Municípios analisados	687
Variáveis candidatas	16
Valores faltantes	0
Combinações de modelo testadas	135
Tabelas geradas	33
Figuras geradas	13
Testes automatizados	27

O que fica de conclusão

Existem 5 tipos de praça para vender fiança, e eles não são geografia nem tamanho de cidade

- O agrupamento passa no teste de aceite: silhueta 0.236 contra -0.001 da geografia e -0.098 do porte.
- É estável: Rand ajustado de 0.847 sob reamostragem.
- E serve como variável de modelo: acrescenta informação em 15 de 15 variáveis retidas, ganho médio +0.0435 no R^2 ajustado.
- A decisão de mídia que ele sustenta: concentrar verba de conversão na praça madura, testar na praça em formação, e EXCLUIR a praça sem mercado formal.

O que ele ainda não faz: dizer quanto a Loft ganha em cada praça. Isso exige o dado interno, e é o próximo passo.